BASIL

Folie **01** · ca. 30 s

Titel

- Begrüssung, Gruppe 6: Basil, Sandro, Kanita
- Leitfrage vorlesen
- 1.08 Mio. Stundenwerte, drei NOAA-Stationen
- Ablauf: Konzept und Daten → Pipeline → Resultate

BASIL

Folie **02** · ca. 50 s

Ausgangslage: Arktis und Antarktis

- Karte: oben Arktis, unten Antarktis, Linien = Polarkreise (66.6°)
- Utqiaġvik: Nordküste Alaska, 11 m
- Summit: Grönlandeis, 3’210 m
- Südpol: Hochplateau, 2’810 m
- Arktis = Meer, Antarktis = Kontinent → unterschiedliches Verhalten erwartet
- Relevant für Meeresspiegel und Klimaprognosen

BASIL

Folie **03** · ca. 50 s

Forschungsfragen und Hypothesen

- FF1: Wie stark sind die Jahresmittel gestiegen? → H1: Utqiaġvik signifikant positiv
- FF2: Arktis schneller als Antarktis? → H2: Trend Arktis steiler als Südpol
- FF3: Welche Jahreszeit am stärksten? → H3: Winter > Sommer in Utqiaġvik
- Alle Hypothesen prüfbar: bestätigen oder verwerfen

BASIL

Folie **04** · ca. 70 s

Vorgehen der Analyse

- Stundenwerte → Monatsmittel (≥ 80 % gültige Stunden) → Jahresmittel (nur volle Jahre)
- Zuerst Monat, dann Jahr: Lücken verzerren nicht
- Anomalie: Abweichung vom Mittel 2009–2025 → Stationen vergleichbar (Südpol ca. 38 °C kälter)
- Trend = Regressionssteigung × 10 = °C pro Jahrzehnt
- Gegenprobe: Mann-Kendall, robust gegen Ausreisser
- Vergleich: nur 32 gemeinsame Jahre, Term Jahr × Arktis

BASIL

Folie **05** · ca. 50 s

Data Engineering Lifecycle

- Nach Reis & Housley (2022), von links nach rechts
- Generation: NOAA-Stationen
- Ingestion: Python, 1 Datei pro Station und Jahr, idempotent
- Storage: Original-Text, Parquet, DuckDB
- Transformation: dbt, 19 Tests
- Serving: bewusst erst in Teil 2
- Unterströmungen: Manifest, Tests, git + uv-Lockfile, run_pipeline.sh
- Überleitung zur Datenquelle

BASIL

Folie **06** · ca. 70 s

Datenquelle: NOAA-Observatorien

2 Folien: zuerst Rohzeile, dann farbig erklärt

- NOAA Global Monitoring Laboratory, Download 23.10.2026 = Generation
- Utqiaġvik ab 1973 (34 volle Jahre), Summit ab 2008 (14), Südpol ab 1975 (43)
- Volles Jahr = 12 Monate mit ≥ 80 % gültigen Stunden
- Rohzeile zeigen und wirken lassen: Was ist welche Zahl? ▶ Klick
- Farben: Wind violett, Druck grün, Temperatur gelb (unser Wert), Feuchte blau, Niederschlag rosa
- Orange gestrichelt = fehlender Wert: −9 Windkonstanz, −99 Niederschlag
- Übergabe an Sandro

→ **Übergabe an Sandro**

SANDRO

Folie **07** · ca. 80 s

Ingestion: Datenbeschaffung

- 5 Schritte: Verzeichnis lesen → Manifest prüfen → Herunterladen → sicher speichern → protokollieren
- Manifest: SHA-256-Hash, Zeilenzahl, Download-Datum
- Bis zu 4 Versuche bei Netzfehlern
- Erst Teildatei, dann umbenennen: nie halbe Dateien
- 1. Lauf: 124 Dateien in ca. 23 s
- 2. Lauf: 121 übersprungen, nur 2026 neu
- Skalierbar: neue Station = 1 Eintrag; Minutenwerte (ca. 60×) mit gleichem Skript

SANDRO

Folie **08** · ca. 80 s

Storage: Evaluation und Umsetzung

- 3 Stufen: Original-Text bleibt → Parquet pro Station → DuckDB
- Original = Beleg für die Herkunft
- Parquet: spaltenbasiert, komprimiert; neue Station = neue Datei
- DuckDB wird von dbt jederzeit neu gebaut, nicht versioniert
- Selbst gemessen: 11× kleiner (75.3 → 6.7 MB), 96× schneller (1'540 → 16 ms)
- Gleiche Abfrage, Median aus 5 Läufen
- PostgreSQL/TimescaleDB = nur Serverbetrieb; MongoDB passt nicht zu Tabellen

SANDRO

Folie **09** · ca. 60 s

Reproduzierbarkeit und Tests

- Zwei Befehle: uv sync, ./run_pipeline.sh
- 124 Dateien → 1’075’602 Zeilen → dbt build PASS=19, ERROR=0
- uv.lock: gleiche Paketversionen für alle
- Frischer Klon ohne Daten, gleiches Resultat auf zwei Rechnern
- Deterministisch: gleiche Daten → byte-gleiche Parquet-Dateien
- Abgabe: Branch «abgabe»
- Überleitung zu dbt

SANDRO

Folie **10** · ca. 50 s

Transformation mit dbt

- 4 Schichten: Rohdaten → stg_noaa_hourly → mart_monthly_temp → mart_annual / mart_seasonal
- Pro Tabelle sagen, was eine Zeile ist: Station × Stunde / Monat / Jahr
- Tests prüfen genau das: doppelte Stunde → Build bricht ab
- Jede Schicht = eine lesbare SQL-Datei
- Saisons nach Hemisphäre: am Südpol ist Dez–Feb Sommer
- Übergabe an Kanita

→ **Übergabe an Kanita**

KANITA

Folie **11** · ca. 60 s

Datenbereinigung

- Fehlcodes → leer: 66’256 Temperaturstunden (BRW 43’900, SPO 20’647, SUM 1’709)
- Plausibilität −90 bis +30 °C: 0 entfernt
- Duplikate: 0 → auch ein Ergebnis, Daten sauber
- Abdeckung: Monat ≥ 80 %, Jahr = 12 Monate → BRW 34, SPO 43, SUM 14
- Fund: Wind steht als −99.9, README sagt −999.9 → negativer Wind = fehlend

KANITA

Folie **12** · ca. 60 s

Resultate H1 und H2: Temperaturtrends

- Grafik lesen: Punkt = volles Jahr als Anomalie, Linie = Trend
- Utqiaġvik +0.95 °C/Jahrzehnt, $p < 0.001$ → H1 bestätigt
- Südpol +0.24, $p = 0.045$, Mann-Kendall nicht signifikant (0.079)
- Unterschied +0.67 °C/Jahrzehnt, $p = 0.001$, 32 Jahre → H2 bestätigt
- Summit +1.13, aber nur 14 Jahre → nicht signifikant

KANITA

Folie **13** · ca. 50 s

Resultat H3: Saisonale Trends

- Utqiaġvik: Herbst +1.60, Frühling +0.91, Winter +0.81, Sommer +0.33
- Winter 0.49 °C/Jahrzehnt stärker als Sommer, p = 0.044 → H3 bestätigt
- Überraschung: Herbst am stärksten
- Mögliche Erklärung: späteres Zufrieren des Nordpolarmeers → noch mit Literatur belegen
- Südpol: kein Saisontrend robust

KANITA

Folie **14** · ca. 40 s

Beantwortung der Forschungsfragen

- FF1: Utqiaġvik +0.95, Südpol +0.24, Summit +1.13 (zu kurz) → H1 bestätigt
- FF2: Ja, Utqiaġvik +0.67 schneller als Südpol (p = 0.001); Summit offen → H2 für Utqiaġvik
- FF3: Herbst am stärksten; Winter > Sommer (p = 0.044) → H3 bestätigt
- Fazit vorlesen

KANITA

Folie **15** · ca. 40 s

Limitationen und Ausblick

- Nur drei Punktstationen in unterschiedlicher Lage
- Lücken in Utqiaġvik → kleinere Stichprobe
- Jahre hängen zusammen → p-Werte eher zu optimistisch
- Instrumentenwechsel nicht korrigiert
- Teil 2: mehr Stationen (AMRDC, MET Norway), Tests mit Autokorrelation, Serving
- Dank und Überleitung zur Diskussion

ALLE

Diskussion · 7 min

Mögliche Fragen

- **Warum DuckDB und kein Server?**
  1 Mio. Zeilen passen auf einen Laptop, DuckDB liest Parquet direkt. Server erst bei viel mehr Daten oder vielen Nutzern. Sandro
- **Was passiert mit Minutenwerten?**
  Rund 60× mehr Daten, gleiches Skript, Parquet pro Station, DuckDB schafft das. Sandro
- **Reichen drei Stationen?**
  Für ganze Pole nicht. Fazit gilt für Utqiaġvik, Teil 2 bringt mehr Stationen. Kanita
- **Warum Referenz 2009–2025?**
  Längste Periode, in der alle drei Stationen messen. Basil
- **Warum die 80-%-Regel?**
  Lückige Monate verzerren das Mittel. Üblicher Kompromiss, in dbt_project.yml änderbar. Kanita
- **Südpol im Mann-Kendall nicht signifikant?**
  Kleiner Trend, starke Schwankung, strengerer Test → «schwacher Trend». Kanita
- **Wie sichert ihr die Datenqualität?**
  19 dbt-Tests, Manifest mit Hash, Original-Text bleibt. Sandro
- **Was kommt im Serving?**
  Dashboard oder Prognose, vor dem Kolloquium festlegen. Basil