BASIL

Folie **01** · ca. 30 s

Titel

Guten Tag zusammen. Wir sind Gruppe 6, das sind Sandro, Kanita und ich, Basil. Unsere Leitfrage lautet: **Erwärmt sich die Arktis schneller als die Antarktis?** Dafür haben wir eine Datenpipeline gebaut, die **über eine Million Stundenwerte** von **drei Wetterstationen** der amerikanischen Behörde NOAA verarbeitet. Ich zeige zuerst das Konzept und die Datenquelle, Sandro erklärt danach die Pipeline, und Kanita zeigt die Datenqualität und unsere Resultate.

BASIL

Folie **02** · ca. 50 s

Ausgangslage: Arktis und Antarktis

Zur Orientierung: Oben auf der Karte ist die Arktis, unten die Antarktis. Wir arbeiten mit drei Stationen. **Utqiaġvik** liegt ganz im Norden von Alaska, direkt an der Küste auf **11 Metern**. **Summit** liegt mitten auf dem Eisschild von Grönland, auf über **3'200 Metern**. Und die dritte Station steht direkt am **Südpol**, auf **2'810 Metern**. Ein wichtiger Unterschied: **Die Arktis ist ein Meer**, das von Land umgeben ist. **Die Antarktis ist ein Kontinent** unter Eis. Wir erwarten deshalb, dass sich die beiden Pole unterschiedlich verhalten. Das ist relevant, weil davon Prognosen zum Meeresspiegel und zum Klima abhängen. Daraus haben wir drei Forschungsfragen abgeleitet.

BASIL

Folie **03** · ca. 50 s

Forschungsfragen und Hypothesen

Unsere erste Frage: Wie stark sind die Jahresmittel an den drei Stationen gestiegen? Wir erwarten, dass **Utqiaġvik einen signifikant positiven Trend** zeigt. Die zweite Frage ist unsere Leitfrage: Erwärmt sich die Arktis schneller als die Antarktis? Unsere Hypothese ist, dass **der Trend in der Arktis steiler ist als am Südpol**. Die dritte Frage: In welcher Jahreszeit ist die Erwärmung am stärksten? Hier vermuten wir, dass sich in Utqiaġvik **der Winter stärker erwärmt als der Sommer**. Wir haben alle drei Hypothesen so formuliert, dass sie sich mit den Daten klar bestätigen oder verwerfen lassen. Wie wir sie prüfen, zeigt die nächste Folie.

BASIL

Folie **04** · ca. 70 s

Vorgehen der Analyse

Wie wird aus über einer Million Stundenwerten eine Zahl pro Jahrzehnt? Zuerst bilden wir Monatsmittel, aber nur für Monate mit **mindestens 80 Prozent** gültigen Stunden. Daraus berechnen wir Jahresmittel, und zwar nur für Jahre mit **allen zwölf Monaten**. So verzerrt ein Monat mit vielen Lücken das Jahr nicht. Dann rechnen wir jedes Jahr in eine **Anomalie** um, also die Abweichung vom Mittel **2009 bis 2025** der jeweiligen Station. Das macht die Stationen vergleichbar, obwohl der Südpol rund **38 Grad kälter** ist als Utqiaġvik. Der Trend ist die Steigung einer Regression, umgerechnet in **Grad pro Jahrzehnt**. Als robuste Gegenprobe nutzen wir zusätzlich den **Mann-Kendall-Test**. Für den Vergleich Arktis gegen Antarktis nehmen wir nur die **32 Jahre**, die an beiden Stationen vollständig sind. Ein Interaktionsterm **Jahr mal Arktis** misst dann, um wie viel steiler der Trend in der Arktis ist.

BASIL

Folie **05** · ca. 50 s

Data Engineering Lifecycle

Unsere Pipeline folgt dem Data Engineering Lifecycle nach **Reis und Housley**. Die Daten entstehen an den NOAA-Stationen, das ist die **Generation**. In der **Ingestion** lädt ein Python-Skript pro Station und Jahr eine Datei herunter, und zwar **idempotent**: Ein zweiter Lauf lädt nichts doppelt. Gespeichert wird in drei Stufen: **Originaltext, Parquet und DuckDB**. Die **Transformation** machen wir mit dbt, abgesichert durch **19 Tests**. Das **Serving**, also zum Beispiel ein Dashboard, setzen wir bewusst **erst in Teil 2** um. Darunter laufen die Unterströmungen wie Datenmanagement, Tests, Versionierung und Orchestrierung. Die erste Stufe, unsere Datenquelle, schauen wir uns jetzt genauer an.

BASIL

Folie **06** · ca. 70 s

Datenquelle: NOAA-Observatorien

2 Folien: zuerst Rohzeile, dann farbig erklärt

Unsere Daten, also die Generation im Lifecycle, stammen vom Global Monitoring Laboratory der **NOAA**. Utqiaġvik hat Dateien ab **1973**, davon sind **34 Jahre** vollständig. Summit misst erst seit **2008**, deshalb hat es nur **14 volle Jahre**. Der Südpol hat Daten ab **1975** und **43 volle Jahre**. Unten sieht man eine echte Rohzeile vom Südpol, genau so, wie sie in der Datei steht: **14 Felder, keine Kopfzeile**, Zeiten in UTC. Ohne Erklärung ist kaum zu erkennen, welche Zahl was ist.
▶ Klick Die Farben zeigen es: violett der Wind, grün der Druck, **gelb die Temperatur**, blau die Feuchte und rosa der Niederschlag. Wichtig sind die **orange gestrichelten Werte**: Fehlende Werte stehen als Codes in der Datei. **Minus 9** heisst, die Windkonstanz fehlt, **minus 99**, der Niederschlag fehlt. Das muss später bereinigt werden, sonst rechnen wir mit **minus 999 Grad**. Wie wir diese Daten automatisch holen und speichern, zeigt jetzt Sandro.

→ **Übergabe an Sandro**

SANDRO

Folie **07** · ca. 80 s

Ingestion: Datenbeschaffung

Danke, Basil. Die Ingestion läuft in **fünf Schritten**. Das Skript liest zuerst das Verzeichnis bei NOAA und findet selbst heraus, welche Jahre es pro Station gibt. Dann prüft es unser **Manifest**. Darin steht für jede Datei ein **SHA-256-Hash**, die Zeilenzahl und das Download-Datum. Ist eine Datei schon da und der Hash gleich, wird sie übersprungen. Beim Herunterladen versucht es bei Netzfehlern bis zu **viermal**. Gespeichert wird zuerst als Teildatei und erst am Schluss umbenannt, so entstehen **nie halbe Dateien**. Der erste Lauf lädt **124 Dateien in rund 23 Sekunden**. Beim zweiten Lauf werden **121 übersprungen**, nur das laufende Jahr 2026 wird neu geladen, weil NOAA es laufend ergänzt. Und wenn wir eine weitere Station oder sogar Minutenwerte wollen, das wären rund **60-mal mehr Daten**, brauchen wir nur **einen Eintrag mehr**, das Skript bleibt gleich.

SANDRO

Folie **08** · ca. 80 s

Storage: Evaluation und Umsetzung

Bei der Speicherung haben wir **drei Stufen**. Der **Originaltext** bleibt unverändert liegen, als Beleg, woher die Daten kommen. Daraus machen wir **pro Station eine Parquet-Datei**. Parquet speichert spaltenweise und komprimiert. Eine neue Station ist einfach eine neue Datei. **DuckDB** liest diese Dateien direkt, und dbt baut die Datenbank jederzeit neu auf, deshalb versionieren wir sie nicht. Die beiden Zahlen oben haben wir **selbst gemessen**, mit derselben Abfrage und dem Median aus fünf Läufen: Parquet ist **elfmal kleiner** als der Text und die Abfrage ist **96-mal schneller**, weil DuckDB nur die benötigten Spalten liest. Wir haben auch Alternativen geprüft. PostgreSQL oder TimescaleDB brächten bei einer Million Zeilen vor allem **zusätzlichen Serverbetrieb**, und MongoDB passt nicht zu so streng tabellarischen Daten. Die ausführliche Bewertung steht im Repo.

SANDRO

Folie **09** · ca. 60 s

Reproduzierbarkeit und Tests

Die ganze Pipeline läuft mit **zwei Befehlen**. uv sync installiert alle Pakete, und zwar dank **Lockfile** für alle in genau derselben Version. Danach startet run_pipeline.sh alles: Die Ingestion holt **124 Dateien**, die Umwandlung erzeugt Parquet mit **1'075'602 Zeilen**, und dbt baut die Modelle und führt **alle 19 Tests** aus, ohne Fehler. Wir haben das auf einem **frischen Klon** getestet, also ganz ohne vorhandene Daten, und auf zwei Rechnern dasselbe Resultat erhalten. Die Pipeline ist zudem **deterministisch**: Wer dieselben Daten neu lädt, erhält **byte-gleiche Parquet-Dateien**. Damit zeigt git nur echte Änderungen. Abgegeben wird der **Branch «abgabe»** im GitHub-Repo. Wie die Daten danach in dbt weiterverarbeitet werden, zeige ich auf der nächsten Folie.

SANDRO

Folie **10** · ca. 50 s

Transformation mit dbt

Die Transformation machen wir mit dbt in **vier Schichten**. Die Rohdaten haben eine Zeile pro Station und Stunde, noch mit Fehlcodes. In der **Staging-Schicht** werden sie bereinigt. Daraus entstehen **Monatsmittel** und schliesslich **Jahres- und Saisonmittel**. Jede Schicht ist eine SQL-Datei, die man lesen und testen kann. Die Tests prüfen vor allem, **was eine Zeile bedeutet**: in Staging genau eine Zeile pro Station und Stunde, in den Monaten eine pro Station und Monat. Kommt eine Stunde doppelt vor, **bricht dbt den Build ab**, bevor ein falscher Mittelwert entsteht. Und weil am Südpol **Dezember bis Februar Sommer** ist, benennt das Modell die Jahreszeiten nach Hemisphäre. Wie sauber die Daten sind und was dabei herauskommt, zeigt jetzt Kanita.

→ **Übergabe an Kanita**

KANITA

Folie **11** · ca. 60 s

Datenbereinigung

Danke, Sandro. Die Bereinigung hat **vier Regeln**. Erstens setzen wir alle **Fehlcodes auf leer**. Ohne diesen Schritt würde minus 999.9 Grad als echte Temperatur in die Mittelwerte einfliessen. Das betrifft **66'256 Temperaturstunden**, allein in Utqiaġvik fast **44'000**. Zweitens prüfen wir die **Plausibilität** zwischen minus 90 und plus 30 Grad, und drittens **Duplikate**. Beide Tests haben **nichts gefunden**. Auch das ist ein Ergebnis: Wir können belegen, dass die NOAA-Daten an dieser Stelle sauber sind. Die vierte Regel ist der wichtigste Entscheid: Ein Monat zählt nur mit **mindestens 80 Prozent** gültigen Stunden, ein Jahr nur mit **zwölf gültigen Monaten**. Dabei haben wir etwas gefunden: Beim Wind steht in den Daten **minus 99.9**, die Dokumentation nennt aber **minus 999.9**. Man darf sich also nicht blind auf die Dokumentation verlassen.

KANITA

Folie **12** · ca. 60 s

Resultate H1 und H2: Temperaturtrends

Jetzt zu den Resultaten. Jeder Punkt ist ein vollständiges Jahr, als Abweichung vom Mittel der jeweiligen Station, und die Linien sind die Trends. Utqiaġvik erwärmt sich um **0.95 Grad pro Jahrzehnt**, hoch signifikant. Damit ist **H1 bestätigt**. Am Südpol sind es nur **0.24 Grad**. Das ist knapp signifikant, im robusten Mann-Kendall-Test aber **nicht mehr**. Der Unterschied zwischen den beiden Stationen beträgt **0.67 Grad pro Jahrzehnt**, mit **p gleich 0.001** über 32 gemeinsame Jahre. Also ist auch **H2 bestätigt**: Utqiaġvik erwärmt sich deutlich schneller als der Südpol. Summit zeigt sogar **plus 1.13 Grad**, aber mit nur **14 Jahren** ist das statistisch noch nicht belastbar.

KANITA

Folie **13** · ca. 50 s

Resultat H3: Saisonale Trends

Bei den Jahreszeiten sieht man: In Utqiaġvik erwärmen sich alle vier Jahreszeiten, aber unterschiedlich stark. Der Winter steigt um **0.49 Grad pro Jahrzehnt stärker** als der Sommer, mit **p gleich 0.044**. **H3 ist also bestätigt**. Überrascht hat uns der **Herbst**: Er steigt mit **1.60 Grad pro Jahrzehnt** am stärksten. Eine mögliche Erklärung ist, dass das Nordpolarmeer **später zufriert** und das offene Wasser im Herbst Wärme abgibt. Das ist aber eine Hypothese, die wir in Teil 2 **mit Literatur belegen** wollen. Am Südpol ist **kein Saisontrend robust**.

KANITA

Folie **14** · ca. 40 s

Beantwortung der Forschungsfragen

Zum Schluss beantworten wir unsere drei Fragen. Erstens: Die Jahresmittel sind gestiegen, **am stärksten in der Arktis**. Zweitens: **Ja, die Arktis erwärmt sich schneller** als die Antarktis. Das können wir für **Utqiaġvik klar belegen**, für Summit ist die Reihe noch zu kurz. Drittens: Am stärksten erwärmt sich der **Herbst**, und der **Winter stärker als der Sommer**. Unser Fazit: **Die Arktis erwärmt sich deutlich schneller als der Südpol, belegt für Utqiaġvik.**

KANITA

Folie **15** · ca. 40 s

Limitationen und Ausblick

Unsere Resultate haben Grenzen. Wir haben nur **drei Punktstationen** in sehr unterschiedlicher Lage, die nicht für den ganzen Pol stehen. **Lücken in Utqiaġvik** verkleinern die Stichprobe. Aufeinanderfolgende Jahre hängen zusammen, deshalb sind die **p-Werte** der Regression **eher zu optimistisch**. Und **Wechsel bei den Messinstrumenten** haben wir nicht korrigiert. In Teil 2 wollen wir **weitere Stationen** einbinden, etwa aus der Antarktis und von Svalbard, Tests verwenden, die den Zusammenhang zwischen den Jahren berücksichtigen, und **das Serving umsetzen**. Code und Daten sind im Repo. **Vielen Dank, wir freuen uns auf eure Fragen.**

ALLE

Diskussion · 7 min

Mögliche Fragen

- **Warum DuckDB und kein Server?**
  1 Mio. Zeilen passen auf einen Laptop, DuckDB liest Parquet direkt. Server erst bei viel mehr Daten oder vielen Nutzern. Sandro
- **Was passiert mit Minutenwerten?**
  Rund 60× mehr Daten, gleiches Skript, Parquet pro Station, DuckDB schafft das. Sandro
- **Reichen drei Stationen?**
  Für ganze Pole nicht. Fazit gilt für Utqiaġvik, Teil 2 bringt mehr Stationen. Kanita
- **Warum Referenz 2009–2025?**
  Längste Periode, in der alle drei Stationen messen. Basil
- **Warum die 80-%-Regel?**
  Lückige Monate verzerren das Mittel. Üblicher Kompromiss, in dbt_project.yml änderbar. Kanita
- **Südpol im Mann-Kendall nicht signifikant?**
  Kleiner Trend, starke Schwankung, strengerer Test → «schwacher Trend». Kanita
- **Wie sichert ihr die Datenqualität?**
  19 dbt-Tests, Manifest mit Hash, Original-Text bleibt. Sandro
- **Was kommt im Serving?**
  Dashboard oder Prognose, vor dem Kolloquium festlegen. Basil