DATA ENGINEERING HS26 · PROJEKTARBEIT TEIL 1

Erwärmt sich die Arktis schneller als die Antarktis?

Eine Datenpipeline über 1.08 Millionen Stundenwerte von drei NOAA-Observatorien



GRUPPE 6

Basil Härri · Sandro Schmuki · Kanita Willner

ZHAW SML


ARKTIS
POLARKREIS 66.6° N
UTQIAĠVIK BRW
71.3°N 156.6°W · 11 m
SUMMIT SUM
72.6°N 38.4°W · 3′210 m
ÄQUATOR 0°
SÜDPOL SPO
90.0°S · 2′810 m
POLARKREIS 66.6° S
ANTARKTIS

Forschungsfragen und Hypothesen

	Forschungsfrage	Hypothese
01	Wie stark sind die Jahresmittel an den drei Stationen gestiegen?	Utqiaġvik zeigt einen signifikant positiven Trend.
02	Erwärmt sich die Arktis schneller als die Antarktis?	Der Trend in der Arktis ist steiler als am Südpol.
03	In welcher Jahreszeit ist die Erwärmung am stärksten?	In Utqiaġvik erwärmt sich der Winter stärker als der Sommer.

KONZEPT UND DATEN

Vorgehen der Analyse

01
Stundenwerte
1.08 Mio. Messungen der Temperatur auf 2 m

→

02
Monatsmittel
nur Monate mit mind. 80 % gültigen Stunden

→

03
Jahresmittel
Mittel der 12 Monate, nur volle Jahre

→

04
Anomalie
Abweichung vom Mittel 2009–2025 der Station

→

05
Trend
Steigung der Regression in °C pro Jahrzehnt

Robuste Gegenprobe

Der Mann-Kendall-Test mit Sen-Steigung prüft denselben Trend ohne Annahme einer Normalverteilung und ist robust gegen Ausreisser-Jahre.

Arktis gegen Antarktis

Nur Jahre, die an beiden Stationen vollständig sind. Der Term Jahr × Arktis in der Regression misst, um wie viel steiler der Trend ist.

KONZEPT UND DATEN

Entwurf des Data Engineering Lifecycle

Generation
NOAA GML: Utqiaġvik, Summit, Südpol

→

Ingestion
Python, 1 Datei pro Station und Jahr, idempotent

→

Storage
Original-Text, Parquet, DuckDB

→

Transformation
dbt: Bereinigung, Mittelwerte, 19 Tests

→

Serving
Teil 2: Dashboard oder Prognose

UNTERSTRÖMUNGEN

Datenmanagement: Manifest mit Hash und Download-Datum · DataOps: dbt-Tests · Software Engineering: git, uv-Lockfile · Orchestrierung: run_pipeline.sh

nach Reis & Housley (2022)

KONZEPT UND DATEN

Datenquelle: NOAA-Observatorien

Utqiaġvik BRW
Alaska · Arktis, Küste

Dateien	volle Jahre	Mittel
1973–2026	34	−10.9 °C

Summit SUM
Grönland · Arktis, Eisschild

Dateien	volle Jahre	Mittel
2008–2026	14	−28.5 °C

Südpol SPO
Antarktis · Hochplateau

Dateien	volle Jahre	Mittel
1975–2026	43	−48.8 °C

SO SIEHT EINE ROHZEILE AUS · EINE STUNDE AM SÜDPOL

```
SPO 2020 01 01 00 118 3.8 -9 686.28 -26.7 -27.2 -26.9 62 -99
```

Quelle: NOAA GML, Download 23.10.2026

KONZEPT UND DATEN

Datenquelle: NOAA-Observatorien

Utqiaġvik BRW
Alaska · Arktis, Küste

Dateien	volle Jahre	Mittel
1973–2026	34	−10.9 °C

Summit SUM
Grönland · Arktis, Eisschild

Dateien	volle Jahre	Mittel
2008–2026	14	−28.5 °C

Südpol SPO
Antarktis · Hochplateau

Dateien	volle Jahre	Mittel
1975–2026	43	−48.8 °C

SO SIEHT EINE ROHZEILE AUS · EINE STUNDE AM SÜDPOL

Station · Zeit (UTC)			Wind			Druck	Temperatur			Feuchte	Niederschlag
SPO	2020 01 01 00		118	3.8	−9	686.28	−26.7	−27.2	−26.9	62	−99
Station	Jahr Mt Tag Std		Richtung °	m/s	Konstanz	hPa	2 m	10 m	Turm	%	mm

Orange gestrichelt = fehlender Wert als Code. In der Datei trennen nur Leerzeichen die 14 Felder, ohne Kopfzeile.

Quelle: NOAA GML, Download 23.10.2026

PIPELINE

Ingestion: Datenbeschaffung

Verzeichnis lesen
findet pro Station alle verfügbaren Jahre selbst

→

Manifest prüfen
schon geladen und Hash gleich? Dann überspringen

→

Herunterladen
bei Netzfehlern bis zu 4 Versuche mit Wartezeit

→

Sicher speichern
erst als Teildatei, dann umbenennen: nie halbe Dateien

→

Protokollieren
SHA-256, Zeilen und Download-Datum ins Manifest

124 Dateien
beim ersten Lauf, in rund 23 Sekunden

121 übersprungen
beim zweiten Lauf, nur 2026 wird neu geladen

+1 Eintrag
für eine weitere Station, das Skript bleibt gleich

PIPELINE

Storage: Evaluation und Umsetzung

11×

kleiner

75.3 MB → 6.7 MB

96×

schneller

1’540 ms → 16 ms

1 · Original-Text bleibt
unverändert, als Beleg für die Herkunft

2 · Parquet pro Station
spaltenbasiert, komprimiert; neue Station = neue Datei

3 · DuckDB-Datenbank
wird von dbt jederzeit aus Parquet neu gebaut

Gemessen mit derselben Abfrage (Jahresmittel pro Station), Median aus 5 Läufen. PostgreSQL oder TimescaleDB brächten bei 1 Mio. Zeilen nur Server-Betrieb, MongoDB passt nicht zu streng tabellarischen Daten.

PIPELINE

Reproduzierbarkeit und Tests

```
$ uv sync
$ ./run_pipeline.sh
1/3 Ingestion ..... 124 Dateien
2/3 Parquet ..... 1’075’602 Zeilen
3/3 dbt build ..... PASS=19 ERROR=0
```

Gleiche Pakete für alle
uv.lock legt jede Version fest

Von null getestet
frischer Klon, ein Befehl, gleiches Resultat

Deterministisch
gleiche Daten ergeben byte-gleiche Parquet-Dateien

Abgabe
Branch «abgabe» im GitHub-Repo

PIPELINE

Transformation mit dbt

Rohdaten

Parquet

1 Zeile = Station × Stunde, noch mit Fehlcodes

→

Staging

stg_noaa_hourly

bereinigt: Fehlcodes leer, unplausible Werte leer, keine Duplikate

→

Monate

mart_monthly_temp

1 Zeile = Station × Monat, mit Anteil gültiger Stunden

→

Jahre, Saisons

mart_annual_temp
mart_seasonal_temp

Jahresmittel, Anomalie, Saisons nach Hemisphäre

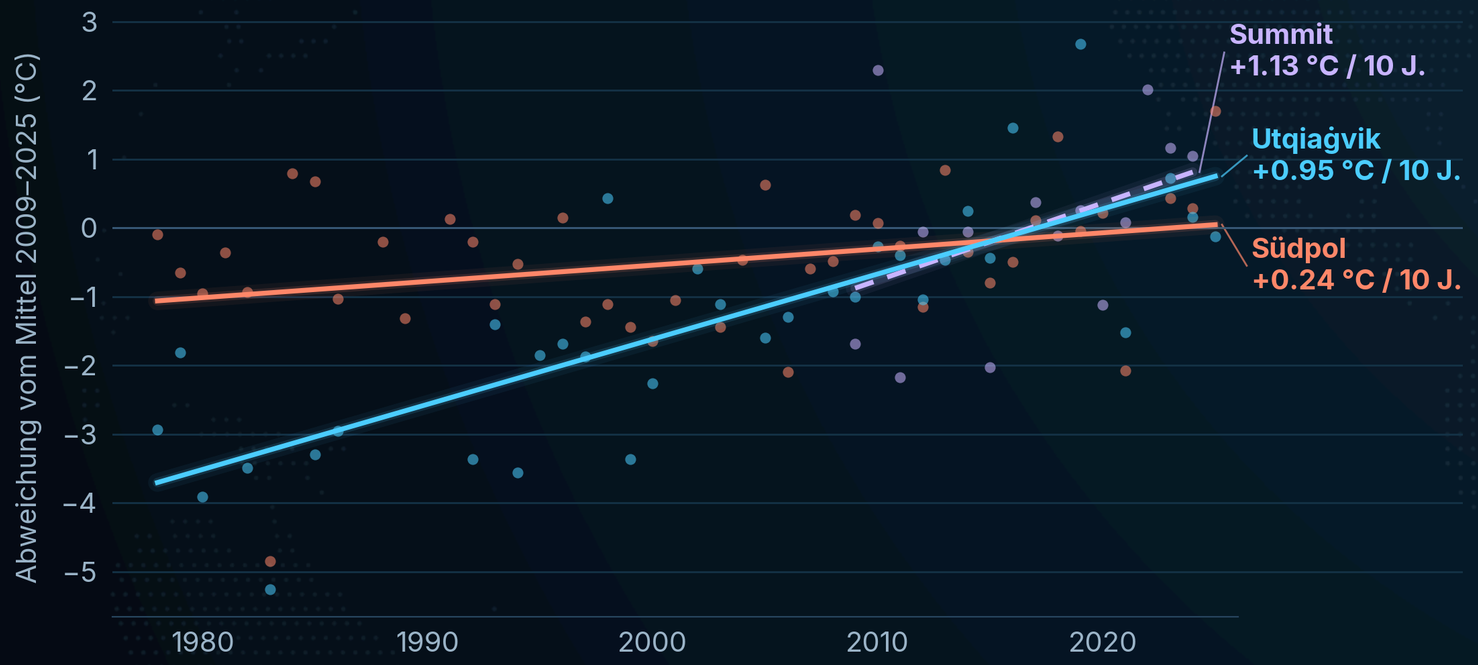
WARUM SO? Jeder Schritt ist eine SQL-Datei, die man lesen und testen kann. dbt baut sie in der richtigen Reihenfolge und stoppt, bevor eine falsche Zahl entsteht: Kommt eine Stunde doppelt vor, schlägt der Test fehl.

Datenbereinigung

Fehlcodes	−999.9, −99, −9 usw. je Feld → leer	**66’256 Temperatur-Stunden leer gesetzt (BRW 43’900, SPO 20’647, SUM 1’709)**
Plausibilität	Temperatur −90 bis +30 °C	**0 Temperaturen entfernt**
Duplikate	1 Zeile pro Station × Stunde	**0 Duplikate gefunden**
Abdeckung	Monat ≥ 80 % Stunden, Jahr = 12 Monate	**volle Jahre: BRW 34, SPO 43, SUM 14**

FUND Bei der Windgeschwindigkeit steht in den Daten −99.9, das NOAA-README nennt −999.9. Wir behandeln deshalb jeden negativen Wind als fehlend.

Resultate H1 und H2: Temperaturtrends



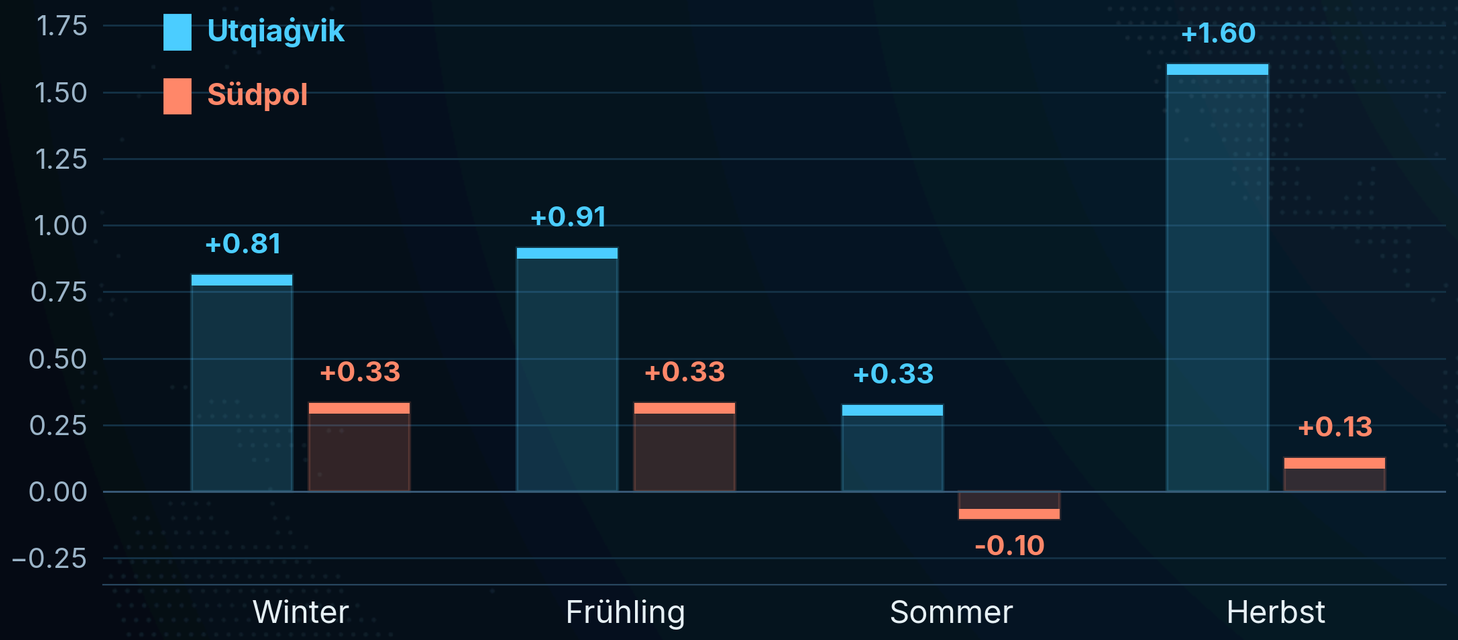
+0.95 °C
pro Jahrzehnt in Utqiaġvik, p < 0.001

+0.24 °C
am Südpol, p = 0.045 (Mann-Kendall: 0.079)

+0.67 °C
Unterschied der Steigung, p = 0.001

Punkt = volles Jahr, Linie = Trend · H1 und H2 bestätigt (32 gemeinsame Jahre)

Resultat H3: Saisonale Trends



H3 BESTÄTIGT

Der Winter erwärmt sich um 0.49 °C pro Jahrzehnt stärker als der Sommer, p = 0.044.

ÜBERRASCHUNG

Der Herbst steigt mit +1.60 °C pro Jahrzehnt am stärksten. Mögliche Erklärung, noch mit Literatur zu belegen: späteres Zufrieren des Nordpolarmeers.

Beantwortung der Forschungsfragen

	FRAGE	ANTWORT	
01	Wie stark sind die Jahresmittel gestiegen?	Utqiaġvik +0.95 °C pro Jahrzehnt, Südpol +0.24 °C, Summit +1.13 °C (Reihe noch zu kurz)	H1 bestätigt
02	Erwärmt sich die Arktis schneller als die Antarktis?	Ja: Utqiaġvik steigt 0.67 °C pro Jahrzehnt schneller als der Südpol ($p = 0.001$). Für Summit noch offen.	H2 bestätigt für Utqiaġvik
03	In welcher Jahreszeit ist die Erwärmung am stärksten?	In Utqiaġvik im Herbst (+1.60 °C pro Jahrzehnt). Der Winter steigt stärker als der Sommer ($p = 0.044$).	H3 bestätigt

FAZIT Die Arktis erwärmt sich deutlich schneller als der Südpol, belegt für Utqiaġvik.

Limitationen und Ausblick

LIMITATIONEN

- Nur drei Punktstationen in unterschiedlicher Lage
- Lücken in Utqiaġvik verkleinern die Stichprobe
- Jahre hängen zusammen: OLS-p-Werte eher zu optimistisch
- Instrumentenwechsel nicht korrigiert

TEIL 2

- Mehr Stationen: AMRDC (Antarktis), MET Norway (Svalbard)
- Robustere Tests mit Autokorrelation
- Serving: [Dashboard oder Prognose festlegen]

Code und Daten: github.com/schmusan/gruppe6-polar